华南师范大学

《人工智能导论》课程项目

开 题 报 告

项　目　题　目：基于 STN 矫正与端到端免分割识别的车牌识别系统研究

所　在　学　院：计算机学院

项　目　组　长：钟艺丹

小　组　成　员：郑涵、万清心

开　题　时　间：2026 年 10 月 24 日

目录

1. 选题背景 2
2. 相关研究综述 2
    2.1. 车牌检测技术研究现状 2
    2.2. 车牌矫正技术研究现状 2
    2.3. 车牌识别技术研究现状 3
    2.4. 现有研究的不足与本课题的切入点 3
3. 拟解决的问题和研究内容 4
    3.1. 拟解决的关键问题 4
    3.2. 研究内容 4
4. 可行性分析 5
    4.1. 小组成员具备的能力和初步分工 5
    4.2. 已有的学习资源 6
    4.3. 可借助的工具或开源代码 6
5. 计划进度安排 7
6. 参考文献 8

1. 选题背景

车牌识别（License Plate Recognition, LPR）是智能交通系统（ITS）的核心技术之一，广泛应用于交通管理、安防监控、停车场管理、电子收费等场景。随着中国机动车保有量的持续增长，城市交通拥堵和违章管理问题日益突出，传统的人工监控方式已无法满足复杂交通场景下的实时管理需求，对高稳定性车牌识别技术的需求愈发迫切。

近年来，深度学习技术的快速发展为车牌识别带来了革命性变化。基于卷积神经网络（CNN）的检测与识别方法在受控条件下已取得显著成果，但在真实复杂场景中——包括光照强度剧烈变化、极端天气干扰、多角度倾斜、低分辨率图像和字符粘连等问题——车牌识别系统的稳定性仍然面临严峻挑战。

当前主流车牌识别系统多采用“检测-分割-识别”的三阶段流程，其中字符分割环节对车牌图像的几何质量高度敏感。当车牌存在倾斜、透视畸变或字符粘连时，分割算法往往失效，导致识别准确率急剧下降。因此，研究一种能够在识别前自动完成几何矫正、且无需字符分割的端到端车牌识别方案，具有重要的理论价值和工程意义。

本课题聚焦于“STN 空间变换网络矫正”与“LPRNet 端到端免分割识别”两个技术点的结合与改进，旨在探索一种在复杂场景下兼具高精度和实时性的车牌识别方案。该方案的技术思路可迁移至其他序列识别任务，具有较强的学术延展性。

2. 相关研究综述

2.1. 车牌检测技术研究现状

车牌检测是识别流程的第一步，其精度直接影响后续识别效果。当前主流方案基于 YOLO 系列目标检测框架。YOLOv8 凭借其 Anchor-Free 设计和 C2f 特征融合模块，在车牌检测任务中表现优异。在 CCPD 数据集上的实验表明，原始 YOLOv8 的 mAP@0.5 可达 95%以上。

为应对复杂场景，研究者提出了多种改进方案。在 YOLOv8 的 Backbone 中嵌入 CBAM 卷积块注意力模块，通过特征融合提升目标检测的准确率，在 CCPD 数据集上实现 mAP@0.5 达 98.7%。CSCM-YOLOv8 方法引入 CPA-Enhancer 预处理模块和 SEAM 自适应权重分配机制，检测精度进一步提升至 98.9%，较原始 YOLOv8 提升 3.1 个百分点。此外，针对低能见度场景，有研究将 AOD-Net 去雾网络集成到 YOLOv8 骨干网络中，使模型同时学习增强和检测任务，在恶劣天气条件下的检测稳定性显著提升。

2.2. 车牌矫正技术研究现状

车牌矫正旨在将倾斜、畸变的车牌图像变换为标准正视角图像，以降低后续字符识别的难度。空间变换网络（Spatial Transformer Network, STN）是当前最常用的矫正方案，其核心思想是通过神经网络自适应地学习仿射变换参数，对输入图像进行空间变换。

STN 在车牌矫正中的有效性已在多项研究中得到验证。有研究将 STN 引入 CRNN 文本识别模型之前，对扭曲变形的车牌进行几何矫正，提升了模型的泛化能力。在 YOLOv5+LPRNet 的级联方

案中，STN 被用于实现车牌倾斜矫正，与 LPRNet 配合完成端到端识别。实验数据表明，在 YOLOv3+LPRNet 的级联网络中，加入 STN 后识别准确率从 66%提升至 93.3%，提升幅度超过 27 个百分点。

然而，STN 也存在局限性。有研究指出，在部分场景下 STN 的矫正效果有限，甚至可能导致字符识别精度下降。另有工作发现 STN 在回归仿射变换矩阵时对车牌倾斜的矫正效果不够理想，提出了 LPTR-AFLNet 等改进方案来克服传统 STN 在透视矫正方面的局限。TransLPRNet 的研究进一步探索了使用 STN 回归 6 参数仿射变换矩阵和 8 参数透视变换矩阵的差异，发现仿射变换的矫正能力有限。这些发现表明，STN 的设计空间——包括变换类型选择（仿射 vs 透视）、网络结构设计和训练策略——仍有较大的改进余地。

2.3. 车牌识别技术研究现状

车牌字符识别经历了从传统方法到深度学习方法的演进。传统方法依赖字符分割和模板匹配，在复杂场景下适应性差。深度学习方法中，LPRNet 是一种轻量级端到端车牌识别网络，由 Intel 团队于 2018 年提出，其核心创新在于无需字符预分割即可直接输出字符序列。

LPRNet 采用全卷积网络结构，使用 CTC（Connectionist Temporal Classification）损失函数处理变长序列对齐问题。CTC 损失函数允许网络在不需要字符级位置标注的情况下进行端到端训练，有效解决了车牌字符长度可变和字符粘连的问题。LPRNet 仅需 0.34 GFLOPs 即可完成单次前向传播，在 GTX 1080 GPU 上单张车牌识别时间仅 3ms，在 Intel i7-6700K CPU 上为 1.3ms，具有极高的推理效率。在中文车牌上，LPRNet 的识别准确率可达 95%。

近年来，研究者对 LPRNet 进行了多方面改进。SE-Bi-LPRNet 在 LPRNet 基础上引入注意力层，融合注意力机制和上下文信息，配合 YOLOv8 进行精确定位。CSM-LPRNet 通过改进网络结构，在复杂场景下字符识别准确率达到 98.56%，较原始 LPRNet 提升 7.0 个百分点。此外，有研究提出使用 ConvLSTM 结合 Connectionist Temporal Softmax 进行无分割识别，进一步探索了序列建模的替代方案。

2.4. 现有研究的不足与本课题的切入点

综合以上分析，现有研究存在以下不足：第一，STN 矫正模块的设计缺乏系统性的消融研究，变换类型（仿射 vs 透视）、网络深度、插入位置等因素对识别精度的影响尚未被充分量化；第二，STN 与 LPRNet 的联合训练策略（端到端联合优化 vs 分阶段训练）对最终性能的影响缺乏对比实验；第三，现有改进方案多聚焦于单一模块的优化，缺乏从检测到矫正再到识别的全链路系统性分析。

本课题以“STN 矫正的改进”为核心切入点，在 YOLOv8 检测+LPRNet 识别的框架下，系统研究 STN 变换类型选择、网络结构设计和训练策略对端到端车牌识别性能的影响，形成一套可复现的消融实验方案和优化建议。

3. 拟解决的问题和研究内容

3.1. 拟解决的关键问题

问题一：STN 矫正模块在车牌识别中的设计缺乏系统性研究。

空间变换网络（STN）在车牌识别中已被广泛用作倾斜矫正的“即插即用”组件，但其设计空间的关键维度尚未被充分量化。已有研究指出，STN 在回归仿射变换矩阵时对车牌倾斜的矫正效果有限，而当 STN 直接用于回归透视变换参数时，输出图像会出现大面积黑色无效区域，导致完整车牌内容无法辨认，其根本原因在于透视变换矩阵参数之间存在高度非线性耦合，微小的参数波动即可引发严重的几何畸变。LPTR-AFLNet 的研究进一步确认，STN 不适用于存在透视畸变的车牌图像，因为其仅考虑了仿射变换而忽略了透视形变。这些发现表明，STN 的变换类型选择、内部网络结构设计以及与识别模块的集成方式，都需要系统性的消融研究来明确其对最终识别精度的影响，而现有文献中缺乏这样的量化分析。

问题二：STN 与 LPRNet 的联合训练策略缺乏对比研究。

现有车牌识别方案中，STN 矫正模块与 LPRNet 识别模块的集成方式存在显著差异。有研究采用端到端联合训练，将 STN 和 LPRNet 作为统一网络进行优化；另有方案采用分阶段训练，先独立训练各模块再联合微调。TransLPRNet 的研究揭示了联合训练中的一个关键矛盾：当识别网络本身能够处理一定程度的倾斜时，矫正网络难以从识别损失中获得有效的反馈调整信号，从而无法准确进行空间矫正，甚至可能加剧车牌图像的几何畸变。这一现象说明，联合训练中损失函数的权重分配、梯度传播路径和训练顺序对最终性能有实质性影响，但这一问题尚未被系统研究。

问题三：复杂场景下车牌识别系统的稳定性不足。

LPRNet 作为一种轻量级车牌识别网络，在受控条件下表现良好，但在复杂环境中识别性能显著下降。在 CCPD2019 复杂环境数据集上，原始 LPRNet 的识别准确率仅为 79.0%。CCPD 数据集虽然提供了涵盖亮度差异（CCPD-DB）、模糊（CCPD-Blur）、远近距离（CCPD-FN）、旋转（CCPD-Rotate）、倾斜（CCPD-Tilt）和综合挑战（CCPD-Challenge）等多个困难场景的子集，但现有改进方案多仅在标准测试集上验证，缺乏在挑战子集上的细粒度性能分析。因此，如何通过 STN 矫正模块的合理设计来提升系统在倾斜、旋转等困难场景下的识别稳定性，是本课题需要解决的核心应用问题。

3.2. 研究内容

（一）车牌检测模块的构建与优化

以 YOLOv8n 为基线模型，在 CCPD2019 数据集上完成车牌检测任务的训练与评估。YOLOv8n 参数量约 3.2M，GFLOPs 约 8.7，适合实时推理场景。重点探索轻量级注意力模块（如 CBAM）在 Backbone 中的插入位置和方式对检测精度的影响，目标是在参数量可控的前提下提升小目标车牌和倾斜车牌的检测能力。已有研究表明，在 YOLOv8 的 Backbone 中嵌入 CBAM 注意力模块，通过特征融合可将 CCPD 数据集上的检测 mAP@0.5 提升至 98.7%。本模块将为后续矫正和识别提供高质量的输入。

（二）STN 矫正模块的设计与消融研究

系统研究 STN 矫正模块的以下设计维度，通过控制变量法设计消融实验，量化各因素对最终识别精度的影响：

变换类型选择：对比 6 参数仿射变换与 8 参数透视变换在车牌矫正中的效果差异。已有研究表明，仿射变换对倾斜矫正能力有限，而透视变换参数回归存在收敛困难和无效区域问题，需要通过实验确定在 CCPD 数据集上的最优变换类型。

STN 内部网络结构：对比不同卷积层数和全连接层维度对变换参数回归精度的影响。定位网络的设计直接决定了变换矩阵参数的学习质量，过浅的网络可能无法充分提取车牌几何特征，过深的网络则可能引入过拟合。

STN 与 LPRNet 的集成方式：对比检测后独立 STN（STN 仅接收检测框裁剪图像）与 STN 与 LPRNet 共享特征（STN 接收检测网络的特征图）两种方案的识别精度和参数量差异。

训练策略：对比端到端联合训练、分阶段训练（先独立训练 STN 和 LPRNet 再联合微调）以及两阶段微调（先冻结 LPRNet 训练 STN，再联合优化）三种策略在收敛速度、最终精度和训练稳定性方面的表现。

（三）LPRNet 识别模块的改进与训练优化

在 LPRNet 基础上探索 CTC 损失函数与其他辅助损失（如交叉熵损失）的组合策略，研究不同权重比对识别精度的影响。结合 CCPD 数据集的标注特点，设计合理的数据预处理和增强流程，包括随机旋转、亮度扰动和运动模糊模拟，以提升模型在挑战场景下的泛化能力。已有研究表明，在 LPRNet 中引入多尺度特征提取模块和注意力机制，可将复杂环境下的识别准确率从 79.0%提升至 86.0%，参数量控制在 2.4MB 以内。本模块将在此基础上进一步优化训练策略和损失函数设计。

（四）端到端系统集成与评估

将检测、矫正、识别三个模块集成为完整的推理流程，在 CCPD 数据集的标准测试集（CCPD-Base）和挑战子集上进行全面评估。挑战子集包括：CCPD-DB（亮度差异）、CCPD-Blur（模糊）、CCPD-FN（远近距离）、CCPD-Rotate（旋转，水平 20°~50°、竖直-10°~10°）、CCPD-Tilt（倾斜，水平 15°~45°、竖直 15°~45°）和 CCPD-Challenge（综合挑战，包含非约束光照、恶劣天气及多种图像处理问题）。评估指标涵盖检测阶段（mAP@0.5、Precision、Recall）、识别阶段（整体识别准确率、字符错误率 CER、词错误率 WER）和系统阶段（端到端识别准确率、推理速度 FPS、模型参数量）。通过对比分析，识别 STN 矫正模块在不同困难场景下的增益差异，明确其最有效的场景类型和性能瓶颈所在。

4. 可行性分析

4.1. 小组成员具备的能力和初步分工

成员 A（算法与模型训练）：具备 Python 编程基础和深度学习入门知识，了解 PyTorch 框架的基本使用，能够完成数据加载、模型构建和训练循环的编写。在本课题中负责 YOLOv8 车牌检测模型的训练与调优、LPRNet 识别模型的训练以及 STN 矫正模块的实现与消融实验设计。该成员已通过前期文献调研掌握了 YOLOv8 的配置文件结构和训练参数设置方法，能够使用 Ultralytics 框架完成模型训练与评估。

成员 B（数据处理与系统集成）：具备 Python 脚本编写能力，熟悉 OpenCV 和 NumPy 图像处理库。负责 CCPD 数据集的下载、文件名解析、标注提取与 YOLO 格式转换，以及训练集/验证集的划分。同时负责将检测、矫正、识别三个模块集成为完整的推理流程，并完成端到端系统的测试与评估。该成员能够参考公开的 CCPD 预处理脚本完成数据解析工作。

成员 C（可视化界面与报告撰写）：具备 PyQt5 或 Streamlit 界面开发基础，了解基本的 GUI 组件使用和信号槽机制。负责开发支持图片、视频和摄像头实时识别的可视化界面，以及绘制训练损失

曲线、准确率对比图等实验图表。同时负责开题报告、中期报告和结题报告的撰写与排版工作。

协同分工机制：三位成员在完成各自核心任务的同时，定期进行代码交叉审查和实验结果讨论。算法成员在完成检测模型训练后，将模型权重和推理接口交付给集成成员；集成成员在完成系统集成后，将推理接口交付给界面成员进行可视化封装。每周进行一次进度同步会议，对照进度计划检查各阶段任务完成情况。由于本课题采用已有的公开数据集 (CCPD) 和成熟的开源框架 (YOLOv8、LPRNet），各模块的技术路线清晰，团队成员通过分工协作可以在预期时间内完成全部研究内容。

4.2. 已有的学习资源

(1) 数据集资源

CCPD（Chinese City Parking Dataset）由中科大团队于 2018 年发布，是中文车牌识别领域规模最大、使用最广泛的公开数据集，相关论文成果发表于 ECCV 2018。CCPD2019 包含约 30 万张蓝色车牌图像，CCPD2020 包含新能源绿色车牌图像，数据集提供 CCPD-DB (亮度差异）、CCPD-Blur（模糊）、CCPD-FN（远近距离）、CCPD-Rotate（旋转）、CCPD-Tilt（倾斜）和 CCPD-Challenge（综合挑战）等多个困难场景子集，为模型在不同场景下的细粒度评估提供了完整的数据支撑。CCPD 的标注信息编码在文件名中，通过解析文件名可提取车牌边界框的左上角和右下角坐标、四个角点坐标、车牌号码、亮度和模糊度等信息。目前已有多篇公开教程和开源脚本详细介绍了 CCPD 文件名的解析方法和 YOLO 格式转换流程。

(2) 公开课程与教程

车牌识别方向的公开学习资源丰富。在视频教程方面，B 站和慕课平台上有多个基于 YOLOv8+LPRNet 的车牌识别全流程实战教程，涵盖数据预处理、模型训练、评估和界面开发各环节。在文字教程方面，CSDN、百度智能云社区等平台上有大量关于 CCPD 数据集预处理、YOLOv8 训练配置和 LPRNet 训练的详细技术博客，如“基于 YOLO 与 LPRNet 的智能车牌识别全流程实战指南”提供了完整的训练代码和参数配置说明。此外，Ultralytics 官方文档提供了 YOLOv8 的详细使用说明和配置文件示例，PyTorch 官方文档和教程涵盖了 STN 的实现原理和代码示例。

(3) 学术论文资源

课题相关的核心论文包括 CCPD 数据集原论文（Xu et al., ECCV 2018）、LPRNet 原论文（Zherzdev & Gruzdev, 2018）和 STN 原论文（Jaderberg et al., NeurIPS 2015）。此外，2025-2026 年发表的关于车牌识别复杂场景改进方案、STN 在车牌矫正中的应用分析等论文为本课题的技术路线设计提供了直接参考。

4.3. 可借助的工具或开源代码

(1) 检测模块：YOLOv8 开源框架

Ultralytics YOLOv8 是当前目标检测领域应用最广泛的开源框架之一，支持通过 pip 直接安装，提供了预训练权重、数据增强、训练配置和模型导出等完整功能。在 CCPD 数据集上，YOLOv8n 可在 RTX 3060 12GB 上以 batch_size=32、imgsz=640 的配置稳定训练，显存占用约 2.4GB。开源社区中有多个基于 YOLOv8 的 CCPD 训练项目可供参考，如 Leo204-LKY/plate-detection-recognition 项目提供了完整的数据集配置文件和训练脚本。

(2) 识别模块：LPRNet 开源实现

LPRNet 的 PyTorch 实现已在 GitHub 上开源，主要包括 sirius-ai/LPRNet_Pytorch 和 Nebuverse/LPRNet 两个仓库。sirius-ai/LPRNet_Pytorch 提供了完整的训练和测试管线，包含数据加载器、LPRNet 网络架构、CTC 损失函数训练脚本和预训练模型权重（Final_LPRNet_model.pth），

模型大小仅 1.7MB，在 GTX 1060 上推理速度 0.5ms，支持中文蓝色车牌和绿色新能源车牌。Nebuverse/LPRNet 在原始实现基础上增加了 STNet 空间校正模块和双层车牌识别支持，在 CCPD 数据集上整体准确率约为 95.1%，可作为 STN 矫正模块的集成参考。

(3) STN 矫正模块的参考实现

STN 在车牌识别中的应用已有多个开源项目可供参考。电子科技大学 CA-USTC 团队的 License_Plate_Recognition_pytorch 项目提供了完整的 YOLOv3+STN+LPRNet 级联方案代码，实验数据表明加入 STN 后识别准确率从 66%提升至 93.3%。该项目代码结构清晰，STN 模块实现简洁（在 LPRNet 中调用 images = STN(images)即可启用车牌矫正），可作为本课题 STN 矫正模块设计和消融实验的直接参考。此外，makram93/spatial_transformer_network 项目提供了 STN 用于车牌倾斜矫正的独立 PyTorch 实现。

(4) 可视化界面

车牌识别系统的 PyQt5 可视化界面已有多个开源实现。xiaozhou-alt/Car_Plate_Recognition 项目提供了基于 YOLOv8+PyQt5 的端到端车牌识别系统，支持图片选择、一键识别和结果保存，直观展示原始图片、检测边界框、裁剪车牌及识别结果。百度智能云社区上也有多个基于 YOLOv8+PyQt5 的开箱即用车牌检测项目，支持图片、视频和摄像头实时检测。本课题的可视化界面可在这些开源项目的基础上进行适配和扩展。

(5) 硬件与训练环境

本课题训练环境采用单卡 NVIDIA RTX 3060（12GB 显存）。YOLOv8n 在 imgsz=640、batch=16 配置下显存占用约 3-4GB，LPRNet 模型参数量极小（1.7MB），可共享同一 GPU 资源进行训练。数据集方面，CCPD-Base 子集约 25 万张图片，存储空间需求约 20GB，本地磁盘可满足。训练框架采用 PyTorch 2.x + Ultralytics，软件环境配置简单，官方提供详细安装指南。

(6) 版本控制与实验管理

代码版本管理采用 Git，配合 GitHub 远程仓库进行协作开发和代码备份。实验管理使用 TensorBoard 记录训练损失曲线、mAP 变化和准确率指标，便于对比不同消融实验的配置和结果。

5. 计划进度安排

阶段	时间	任务
一、前期调研与开题准备	第 1-6 周	第 1-2 周：文献调研，系统阅读 CCPD、LPRNet、STN 及相关改进论文；第 3-4 周：完成 CCPD 数据集下载、文件名解析与 YOLO 格式转换，搭建 PyTorch+Ultralytics 开发环境；第 5-6 周：YOLOv8n 检测基线初步训练，LPRNet 识别基线初步训练，整理开题报告所需材料
二、开题报告	第 7 周	撰写并提交项目开题报告；根据开题评审意见调整技术路线与实验方案
三、技术方案设计与实验阶段	第 8-11 周	第 8-9 周：实现 STN 矫正模块，完成与 LPRNet 的串联集成；第 10-11 周：开展消融实验 E1-E4——变换类型（仿射 vs 透视）、定位网络深度、STN 插入位置、训练策略（端到端联合训练 vs 分阶段训练）；同步进行损失函数优化实验 E5 和检测模块改进实验 E6
四、进度检查	第 12 周	提交进度检查材料，汇报技术方案与实验方案；根据检查意见调整后续实验重点
五、系统集成与	第 13-15 周	将检测、STN 矫正、LPRNet 识别集成为完整推理流程；在 CCPD-Base

评估		标准测试集和 CCPD-DB、CCPD-Blur、CCPD-FN、CCPD-Rotate、CCPD-Tilt、CCPD-Challenge 挑战子集上进行端到端评估；与 YOLOv3+STN+LPRNet、YOLOv5+LPRNet 等基线进行对比；开发可视化界面
六、项目总结与汇报	第 16 周	整理全部实验数据与图表；撰写结题报告；准备答辩 PPT；进行项目汇报与演示

6. 参考文献

[1] Xu Z, Yang W, Meng A, et al. Towards end-to-end license plate detection and recognition: A large dataset and baseline[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 255-271.

[2] Zherzdev S, Gruzdev A. LPRNet: License plate recognition via deep neural networks[J]. arXiv preprint arXiv:1806.10447, 2018.

[3] Jaderberg M, Simonyan K, Zisserman A, et al. Spatial transformer networks[C]//Advances in Neural Information Processing Systems. 2015: 2017-2025.

[4] 基于改进 YOLOv8 和 LPRNet 的车牌识别算法[J]. 沈阳理工大学学报, 2025(3).

[5] Xiong W, Cao L, Yan D, et al. License plate recognition methodology in complex scenarios based on CSCM-YOLOv8 and CSM-LPRNet[J]. PLoS One, 2026, 21(1): e0339649.

[6] Deep learning algorithms for license plate recognition: A review[J]. Neural Networks, 2026.

[7] Hybrid deep learning frameworks for license plate recognition in complex environments: A comprehensive survey and research outlook[J]. IET Computer Vision, 2026.

[8] Towards robust license plate recognition in real-world surveillance: A systematic literature review[J]. IEEE Access, 2026.

[9] LPTR-AFLNet: Lightweight integrated Chinese license plate rectification and recognition network[J]. arXiv preprint.

[10] License plate recognition system based on convolutional neural network multi model fusion[C]//IEEE Conference. 2024.